Projet

Apprentissage Automatique

Clustering d'images d'aliments — Dataset Snacks

Raphaël Charton & Julien Bougues

ET4 — Polytech Paris-Saclay

Année 2025–2026

Table des matières

Introduction 4
Modèles 5
K-Means 5
DBSCAN 5
Hierarchical Clustering 5
Descripteurs 7
Histogramme de niveaux de gris 7
HOG (Histogram of Oriented Gradients) 7
LBP (Local Binary Pattern) 7
BoVW (Bag of Visual Words) 7
Métriques d'évaluation 9
Résultats expérimentaux 10
K-Means + Histogramme 10
Avec PCA 10
Sans PCA 10
DBSCAN + Histogramme 11
Avec PCA 11
Sans PCA 12
Hierarchical Clustering + Histogramme 12
K-Means + HOG 13
Avec PCA 13
Sans PCA 13
DBSCAN + HOG 15
Avec PCA 15
Sans PCA 15
Hierarchical Clustering + HOG 16
K-Means + LBP 16
DBSCAN + LBP 17
Hierarchical Clustering + LBP 17
K-Means + BoVW 18
Avec PCA 18
Sans PCA 18
DBSCAN + BoVW 19
Avec PCA 19
Sans PCA 19

Hierarchical Clustering + BoVW 20
Répartition du travail 21
Julien 21
Raphaël 21
Conclusion 22
Pistes d'amélioration 22

Introduction

L'évolution du numérique ainsi que la croissance exponentielle des données visuelles ont fait de la classification automatique d'images l'un des défis centraux de l'intelligence artificielle. Contrairement aux approches supervisées qui s'appuient sur des étiquettes prédéfinies, le clustering (ou regroupement non supervisé) permet de regrouper les images selon leur similarité visuelle intrinsèque, sans connaissance a priori des classes.

Dans le cadre de ce projet, nous nous intéressons au clustering d'images d'aliments à partir du jeu de données **Snacks**. L'objectif est de comparer différents modèles et descripteurs afin d'évaluer leurs forces et faiblesses respectives :

- Les **descripteurs** permettent d'extraire des informations numériques de chaque image, chacun avec sa spécificité.
- Les **modèles de clustering** (K-Means, DBSCAN, Hierarchical Clustering) définissent la stratégie de regroupement.
- Les **métriques d'évaluation** mesurent la cohésion interne des clusters ainsi que leur séparation.

Ce rapport présente nos choix techniques, les justifications qui les accompagnent, ainsi qu'une analyse comparative des résultats obtenus sur le dataset Snacks.

Modèles

Le choix des algorithmes de clustering est déterminant pour la qualité des regroupements obtenus, car chaque méthode repose sur des hypothèses géométriques et statistiques propres. Nous comparons trois approches complémentaires :

- **K-Means** : méthode de référence permettant de fixer directement le nombre de clusters à 20, correspondant à nos classes connues.
- **DBSCAN** : approche basée sur la densité, capable de détecter des clusters de forme arbitraire et d'isoler le bruit.
- **Hierarchical Clustering (Ward)** : approche hiérarchique montrant l'organisation des données à plusieurs niveaux, produisant des groupes compacts et équilibrés.

L'utilisation conjointe de ces trois modèles permet de varier les approches et de mieux comprendre quel algorithme est le plus adapté à notre problématique.

K-Means

K-Means est un algorithme de clustering qui initialise k centres, puis assigne chaque point au centre le plus proche. Les centres sont ensuite recalculés comme la moyenne des points assignés. Cette étape est répétée jusqu'à convergence ou jusqu'à atteindre le nombre maximal d'itérations.

Dans notre cas, **k = 20** puisque le nombre de classes est connu. L'algorithme cherche à minimiser la distance intra-cluster. Cependant, il reste sensible à l'initialisation des centres et aux valeurs aberrantes.

DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) identifie les clusters comme des régions denses de points. Il repose sur deux hyperparamètres : **ε** (rayon de voisinage) et **MinPts** (nombre minimal de points requis pour qu'un point soit considéré comme un « core point »).

Cet algorithme détecte des clusters de forme arbitraire et identifie les valeurs aberrantes comme du bruit. Cependant, il ne nécessite pas de fixer un nombre de clusters a priori, ce qui peut être un avantage dans certains cas, mais pas dans le nôtre. De plus, il est très sensible au choix de ε et MinPts, et ses performances se dégradent en haute dimension.

Hierarchical Clustering

Le clustering hiérarchique adopte une approche ascendante : chaque image est initialement considérée comme un cluster, puis les clusters les plus proches fusionnent itérativement jusqu'à obtenir un unique cluster englobant toutes les données. Ce processus crée une représentation arborescente (dendrogramme) permettant de choisir le niveau de découpe souhaité.

La notion de proximité est définie par le critère de liaison (linkage) :

- **Ward** : minimise la variance intra-cluster lors de chaque fusion (clusters compacts et équilibrés).

- **Complete** : se base sur la distance maximale entre deux points de clusters différents.
- **Average** : utilise la distance moyenne entre tous les points des deux clusters.

Choix des paramètres

Nous avons fixé le nombre de clusters à 20 pour correspondre aux 20 classes du dataset Snacks. Pour chaque descripteur, nous avons testé plusieurs combinaisons de critère de liaison (linkage) et de mesure de distance, puis retenu celle qui maximisait l'AMI (avec la silhouette comme critère de départage) :

- **HOG** : liaison *average* + distance euclidienne, avec une réduction PCA à 40 composantes maximum.
- **Histogramme de niveaux de gris** : liaison *ward* + distance euclidienne, avec standardisation des données.
- **LBP** : liaison *ward* + distance euclidienne, avec une PCA à 3 composantes et blanchiment (*whiten=True*) pour décorréler les dimensions.
- **BoVW** : liaison *average* + distance cosinus, avec un vocabulaire SIFT de 150 mots visuels, suivi d'une standardisation.

Le choix de la distance cosinus pour BoVW s'explique par la nature de ce descripteur : il produit des histogrammes de fréquences pour lesquels c'est la proportion relative des mots visuels qui compte, plus que la valeur absolue. Pour les autres descripteurs, la distance euclidienne convient mieux car leurs dimensions sont directement comparables entre elles. Les prétraitements (standardisation, PCA, taille du vocabulaire) ont été adaptés descripteur par descripteur afin d'obtenir les clusters les plus nets possibles.

Descripteurs

La qualité d'un pipeline de clustering repose en grande partie sur les descripteurs et leur capacité à capturer les informations visuelles pertinentes d'une image sous forme de vecteurs numériques. Nous avons sélectionné quatre descripteurs capturant des propriétés visuelles complémentaires :

- **Histogramme de niveaux de gris** : descripteur de référence, représentant la distribution globale de luminosité.
- **HOG** : capture l'information de contours et de formes des aliments.
- **LBP** : caractérise les micro-textures de surface, complémentaire aux contours.
- **BoVW** : descripteur le plus élaboré, représentant une image par la fréquence de structures locales, offrant une robustesse aux variations de cadrage.

Ce choix progressif, du plus simple au plus complexe, nous permet d'évaluer l'impact de la richesse du descripteur sur les résultats.

Histogramme de niveaux de gris

Le descripteur histogramme convertit une image en niveaux de gris et produit une représentation de la distribution des pixels selon leur intensité. Cependant, il ne contient aucune information spatiale : deux images visuellement différentes mais ayant une répartition de luminosité similaire auront des histogrammes proches.

HOG (Histogram of Oriented Gradients)

HOG capture les contours et formes présentes dans une image. L'image est divisée en petites cellules, puis pour chaque cellule, un histogramme des orientations des gradients est calculé. Ces histogrammes sont normalisés et fusionnés pour former le descripteur final. Cependant, HOG ne capture pas les couleurs.

LBP (Local Binary Pattern)

LBP est un descripteur de texture analysant le voisinage local de chaque pixel. Pour chaque pixel, on compare sa valeur avec celles de ses 8 voisins : si le voisin a une valeur supérieure ou égale, on lui attribue un 1, sinon un 0. On obtient ainsi une séquence binaire de 8 bits convertie en un nombre décimal (code LBP). L'histogramme de tous les codes LBP forme le vecteur descripteur final de dimension 256.

BoVW (Bag of Visual Words)

BoVW est inspiré du modèle Bag of Words appliqué aux images. L'idée est de décrire une image par la fréquence d'apparition de « mots visuels ».

Le processus se décompose en plusieurs étapes : d'abord, des points d'intérêt sont détectés sur les images à l'aide d'algorithmes comme **SIFT** (qui identifie les extrema locaux dans un espace multi-échelle) ou **ORB** (qui détecte les pixels dont le voisinage présente un fort contraste). Ensuite, les

descripteurs locaux de toutes les images d'entraînement sont regroupés par K-Means en k clusters, chacun représentant un « mot visuel ». Enfin, chaque image est représentée par un histogramme de taille k comptant le nombre de descripteurs correspondant à chaque mot visuel.

Métriques d'évaluation

Nous avons retenu deux métriques complémentaires pour évaluer la qualité de nos clusterings :

- **AMI (Adjusted Mutual Information)** : mesure la correspondance entre les clusters prédits et les classes réelles. Un score élevé indique que les points sont placés dans les bons clusters. Lorsque AMI < 0 alors le clustering est moins bon que de l'aléatoire, AMI = 0 est un jeu de données aléatoires et plus AMI est proche de 1 plus le clustering est efficace.
- **Silhouette Score** : évalue la cohésion interne et la séparation des clusters. Un score proche de 1 indique des clusters denses et bien séparés ; un score négatif indique un chevauchement entre clusters.
  Si silhouette score < 0 alors le point est plus proche d'un autre cluster que du sien, si silhouette score est aux alentours de 0 alors le point est entre son cluster et un autre et plus silhouette score est proche de 1 plus le point est proche de son cluster.

Nous avons gardé seulement ces deux-là car nous trouvons que ces deux métriques peuvent résumer l'efficacité d'un clustering. En effet, si la distance intra et inter cluster est bonne et que les points des clusters prédit sont dans les bons clusters alors le clustering aura fonctionné.

Résultats expérimentaux

Cette section présente les résultats obtenus pour chaque combinaison modèle/descripteur. Pour chaque expérience, nous avons normalisé les données et, lorsqu'indiqué, appliqué une réduction de dimensionnalité par PCA.

K-Means + Histogramme

L'histogramme de niveaux de gris ne capture que la distribution de luminosité, ce qui s'avère peu discriminant pour des images d'aliments. Après normalisation et réduction PCA (dimension 256 → n_components), les résultats restent faibles :

Avec PCA

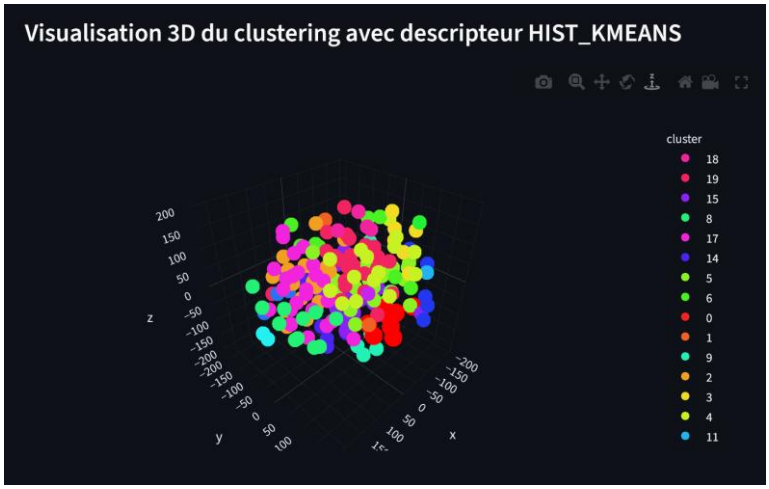


Figure 1 — K-Means + Histogramme (avec PCA)

Métrique	Score
Silhouette Score	**0.08**
AMI	**0.02**

Sans PCA

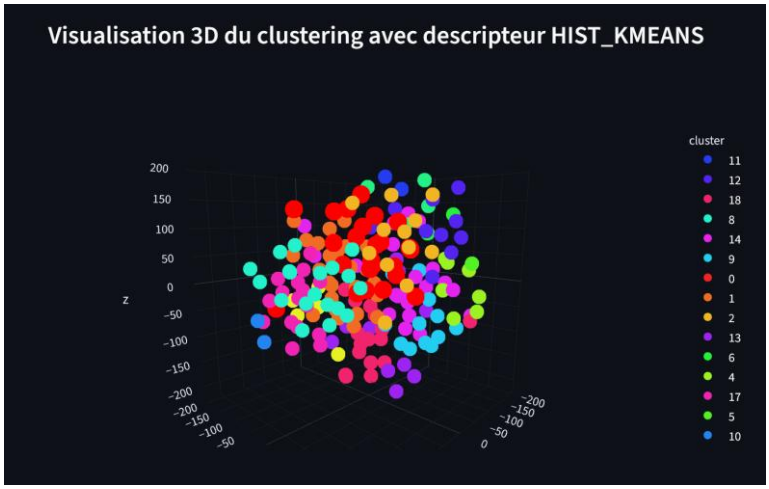


Figure 2 — K-Means + Histogramme (sans PCA)

Métrique	Score
Silhouette Score	**0.03**
AMI	**0.00**

La réduction PCA améliore sensiblement les résultats : les points sont mieux regroupés et les clusters plus clairement séparés. Néanmoins, les scores restent très bas, confirmant les limites de ce descripteur.

DBSCAN + Histogramme

Après exploration de plusieurs combinaisons de paramètres (ε, min_samples, métrique cosine vs. euclidienne), les meilleurs résultats sont obtenus avec la métrique euclidienne, **ε = 0.5** et **min_samples = 3**, pour un total de 14 clusters.

Avec PCA

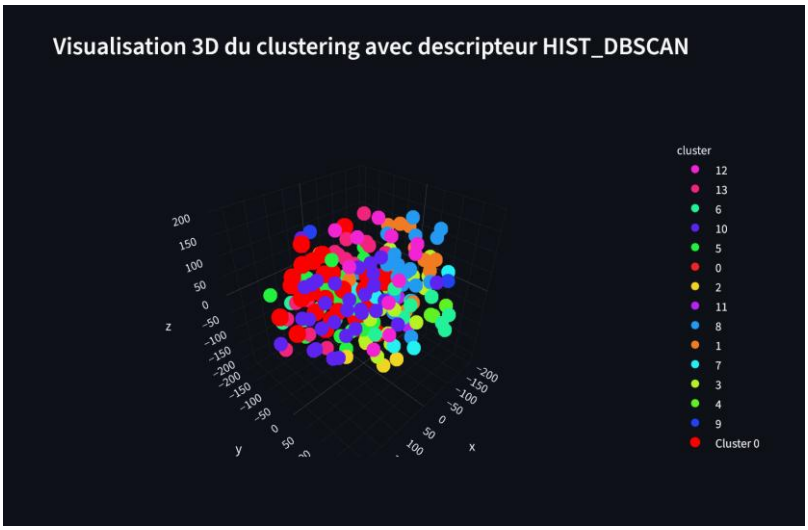


Figure 3 — DBSCAN + Histogramme (avec PCA)

Métrique	Score

Silhouette Score	**0.05**
AMI	**0.03**

Sans PCA

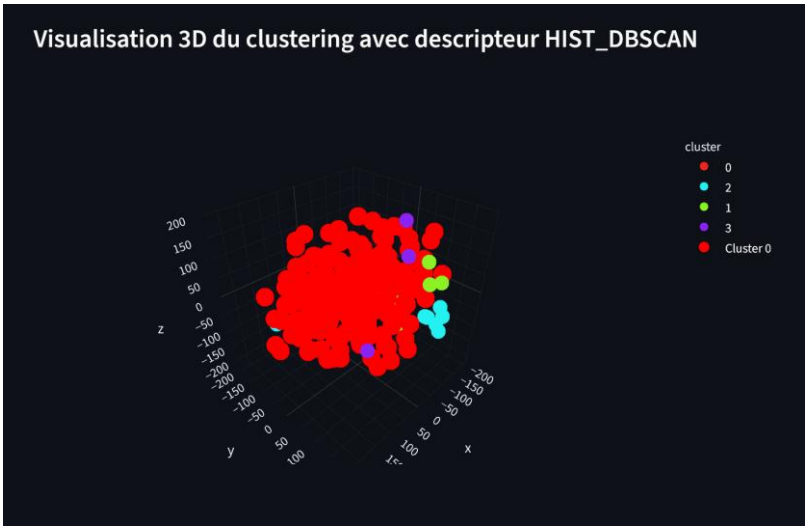


Figure 4 — DBSCAN + Histogramme (sans PCA)

Métrique	Score
Silhouette Score	**0.08**
AMI	**0.00**
Clusters trouvés	**4**

Sans PCA, l'algorithme ne trouve que 4 clusters, confirmant la forte sensibilité de DBSCAN à la haute dimensionnalité. Le clustering n'est pas pertinent.

Hierarchical Clustering + Histogramme



Figure 5 — Hierarchical Clustering + Histogramme (avec PCA)

Métrique	Score
Silhouette Score	**0.0304**
AMI	**0.0185**

C'est la combinaison la moins performante. L'histogramme de niveaux de gris perd trop d'informations importantes pour des images d'aliments (couleurs, textures).

K-Means + HOG

Avec PCA

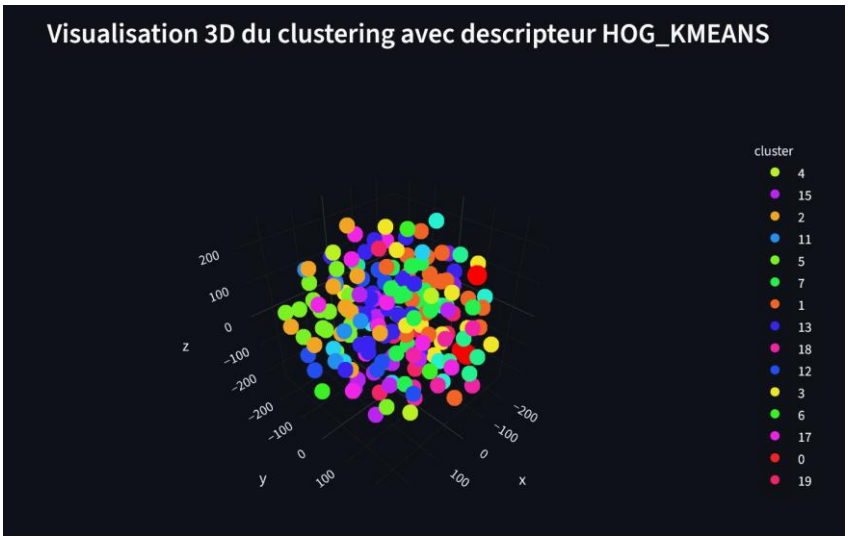


Figure 6 — K-Means + HOG (avec PCA)

Métrique	Score
Silhouette Score	**0.00**
AMI	**0.01**

Les clusters sont mal séparés et les images ne sont pas forcément dans les bons clusters.

Sans PCA

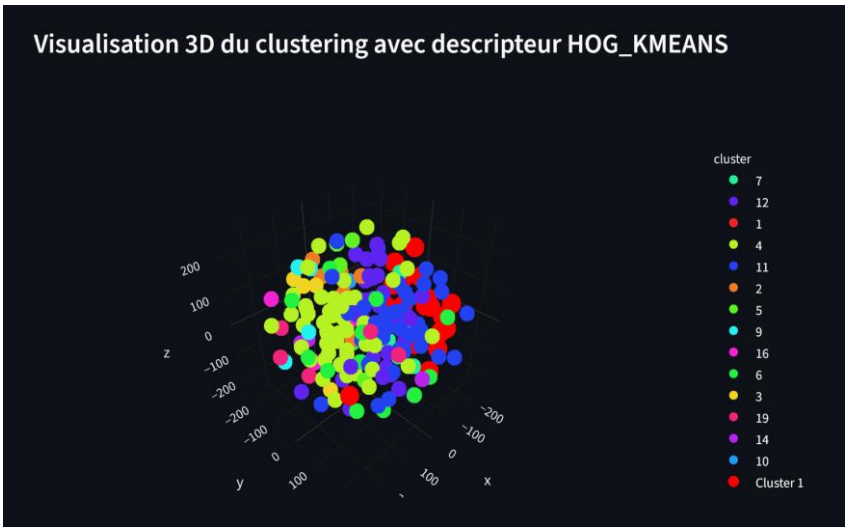


Figure 7 — K-Means + HOG (sans PCA)

Métrique	Score
Silhouette Score	**-0.01**
AMI	**0.03**

Sans PCA, le score AMI est plus élevé, indiquant davantage d'images correctement regroupées. Cependant, la silhouette négative montre que les clusters se chevauchent. Cela peut s'expliquer par la nature de HOG (détection de formes) et la qualité variable des images du dataset.

DBSCAN + HOG

Meilleurs paramètres : **ε = 0.5**, **min_samples = 3**.

Avec PCA

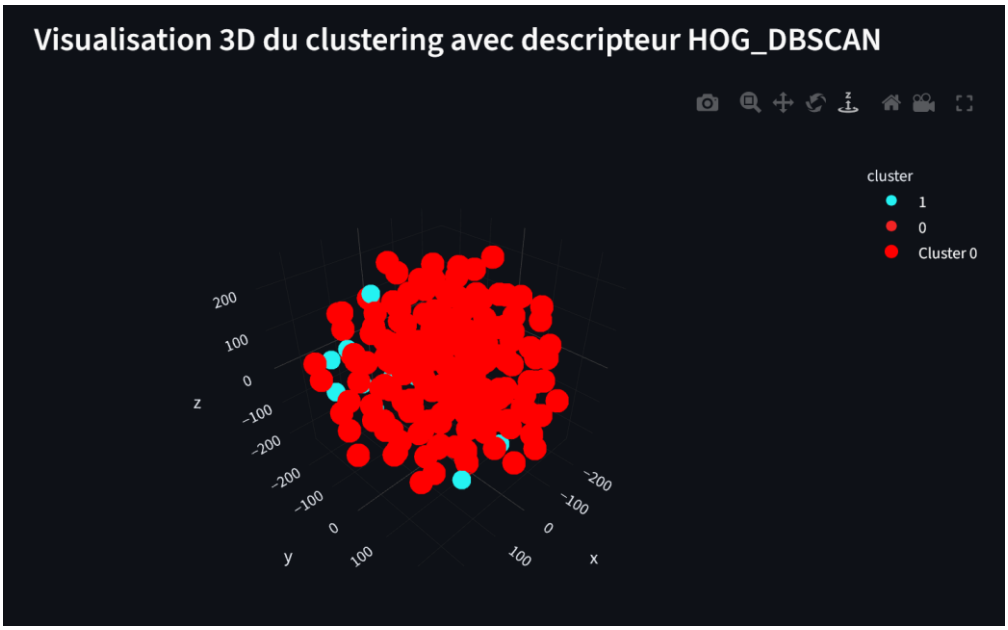


Figure 8 — DBSCAN + HOG (avec PCA)

Métrique	Score
Silhouette Score	**0.17**
AMI	**0.00**
Clusters trouvés	**2**

Le score de silhouette paraît élevé, mais il s'explique par la présence de seulement deux clusters. Le cluster principal est suffisamment compact pour tirer le score vers le haut.

Sans PCA

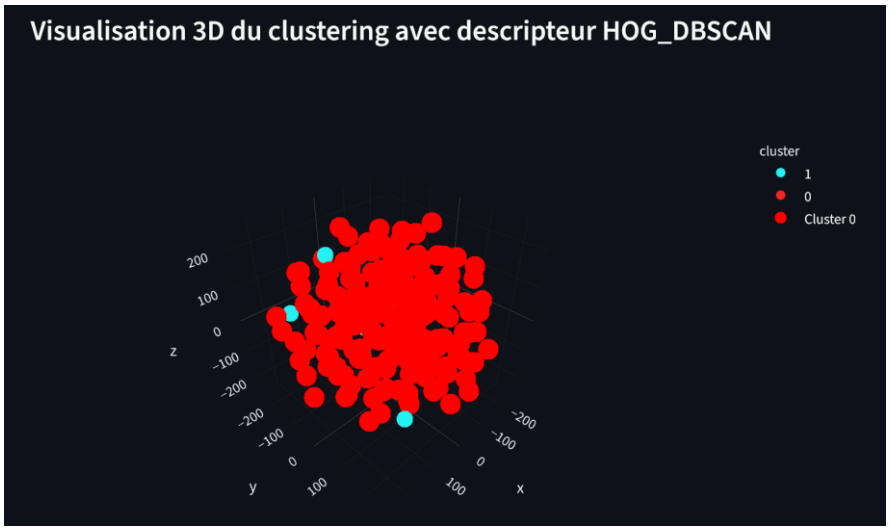


Figure 9 — DBSCAN + HOG (sans PCA)

Métrique	Score
Silhouette Score	**0.12**
AMI	**0.00**

Ces résultats confirment que DBSCAN n'est pas adapté à la classification dans un contexte où le nombre de classes est connu.

Hierarchical Clustering + HOG

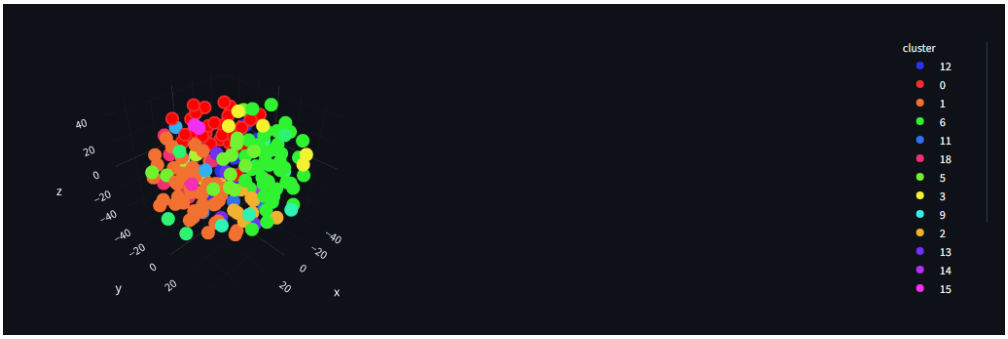


Figure 10 — Hierarchical Clustering + HOG (avec PCA)

Métrique	Score
Silhouette Score	**-0.0082**
AMI	**0.0540**

L'AMI est correct, mais la silhouette négative indique des frontières faibles et un chevauchement entre clusters. Le modèle retrouve partiellement l'information de classe, sans parvenir à former des groupes bien séparés.

K-Means + LBP



Figure 11 — K-Means + LBP (avec PCA)

Métrique	Score
Silhouette Score	**0.1850**
AMI	**0.0582**

C'est la méthode la plus équilibrée du lot : les clusters sont mieux structurés (silhouette positive) tout en conservant un AMI correct.

DBSCAN + LBP

Meilleurs paramètres : **ε = 0.5**, **min_samples = 3**.



Figure 12 — DBSCAN + LBP (sans PCA)

Métrique	Score
Silhouette Score	**0.1919**
AMI	**0.0616**
Clusters trouvés	**3**

Le score de silhouette est le plus élevé, mais ce résultat doit être interprété avec prudence : l'algorithme ne détecte que 3 clusters avec beaucoup de bruit (748 points). Le modèle est trop global et ne distingue pas les 20 classes.

Hierarchical Clustering + LBP

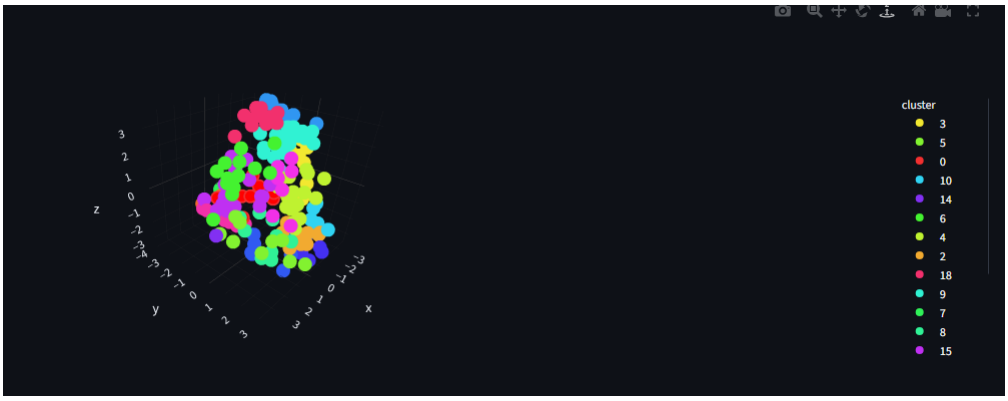


Figure 13 — Hierarchical Clustering + LBP (avec PCA)

Métrique	Score
Silhouette Score	**0.1633**
AMI	**0.0564**

Meilleur compromis parmi les variantes hiérarchiques. LBP capture bien la texture locale, ce qui améliore à la fois la précision et la fidélité aux classes.

K-Means + BoVW

Avec PCA

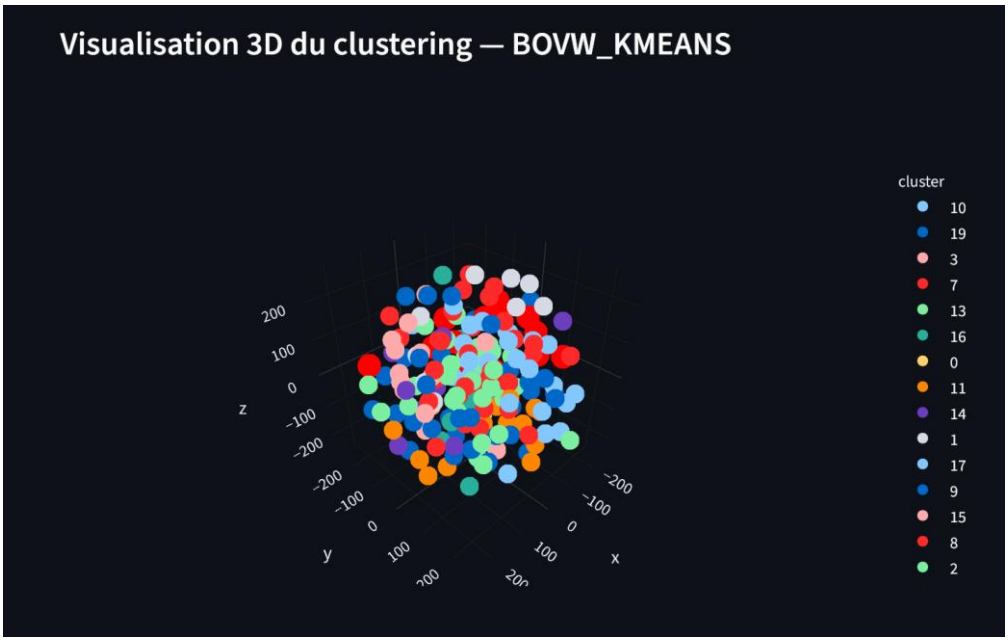


Figure 14 — K-Means + BoVW (avec PCA)

Métrique	Score
Silhouette Score	**0.00**
AMI	**0.08**

Le score AMI est le plus élevé obtenu avec K-Means, indiquant davantage de points correctement regroupés. Cependant, la silhouette à 0.00 montre des clusters mal définis, difficilement identifiables visuellement.

Sans PCA

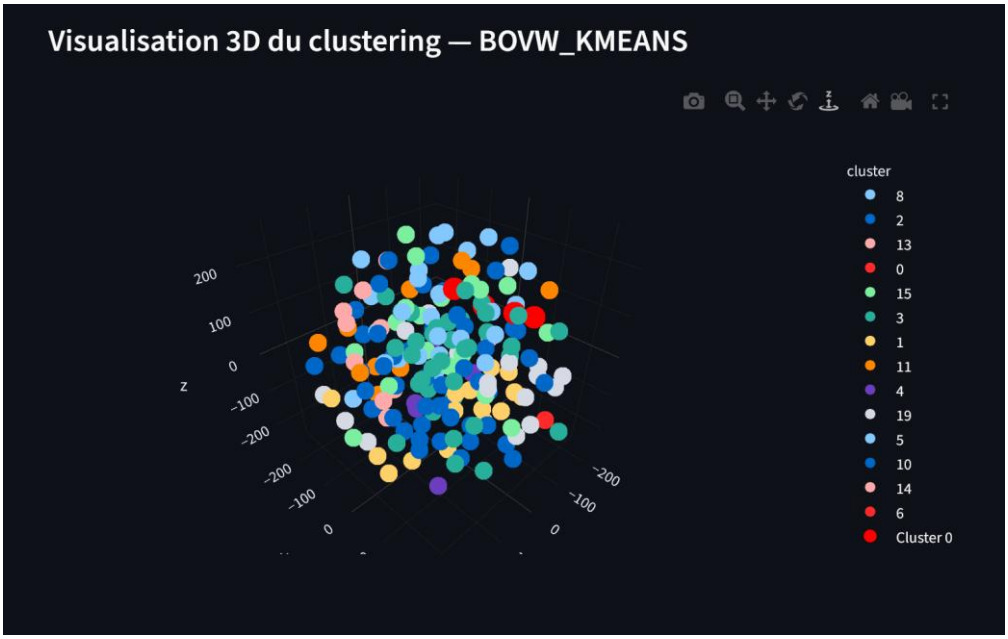


Figure 15 — K-Means + BoVW (sans PCA)

Métrique	Score
Silhouette Score	**-0.02**
AMI	**0.07**

Sans PCA, la silhouette se dégrade légèrement et l'AMI diminue marginalement.

DBSCAN + BoVW

Paramètres : **ε = 0.5**, **min_samples = 7**.

Avec PCA

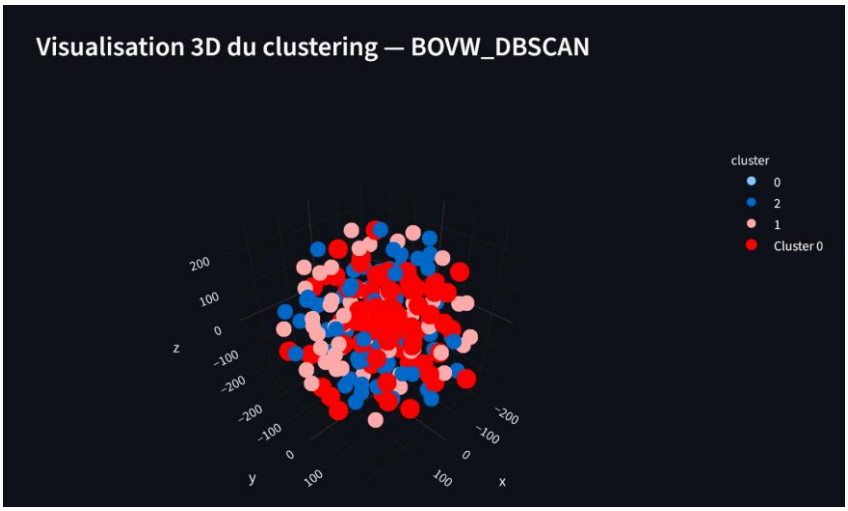


Figure 16 — DBSCAN + BoVW (avec PCA)

Métrique	Score
Silhouette Score	**0.02**
AMI	**0.01**
Clusters trouvés	**5**

Sans PCA

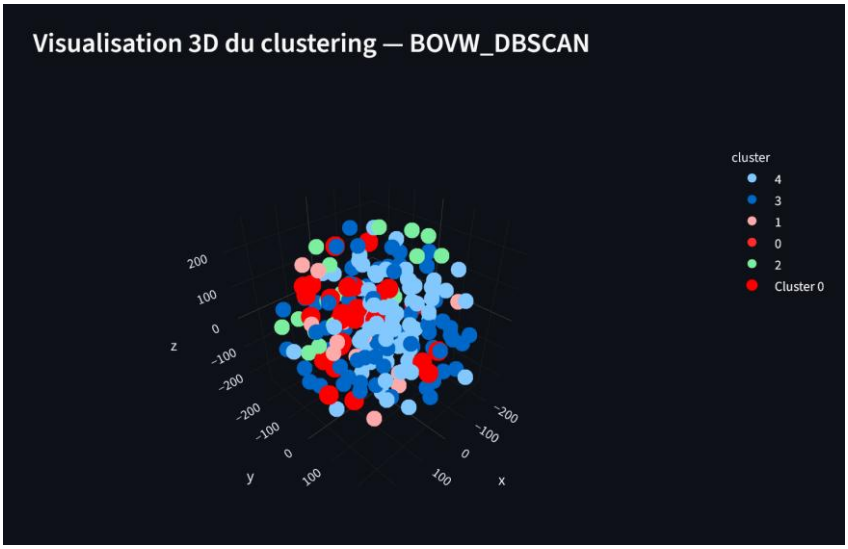


Figure 17 — DBSCAN + BoVW (sans PCA)

Métrique	Score
Silhouette Score	**0.01**
AMI	**0.05**

Hierarchical Clustering + BoVW

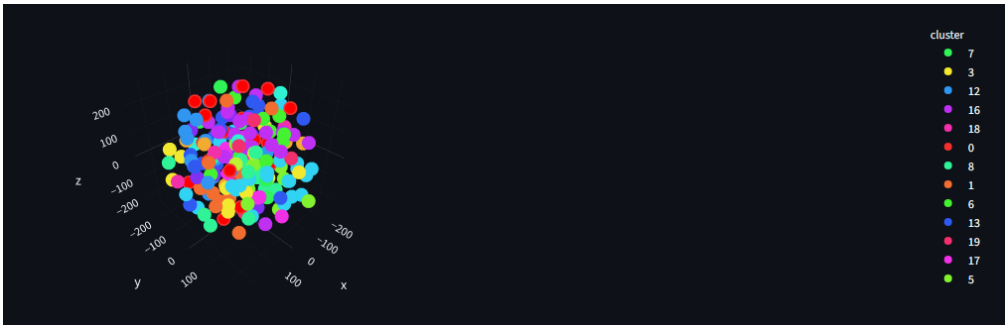


Figure 18 — Hierarchical Clustering + BoVW (sans PCA)

Métrique	Score
Silhouette Score	**-0.0574**
AMI	**0.0722**

Meilleur AMI du bloc hiérarchique, indiquant une bonne corrélation avec les classes. Toutefois, la silhouette négative montre que les clusters sont mal séparés.

BoVW étant un descripteur plus complexe, nous attendions de meilleurs résultats.

Répartition du travail

Julien

- Explication des descripteurs
- Explication des choix des modèles et descripteurs
- Hierarchical Clustering (HOG, Histogramme, LBP, BoVW)
- K-Means + LBP
- DBSCAN + LBP

Raphaël

- Explication des modèles
- Explication des choix des métriques
- Introduction, conclusion et pistes d'amélioration
- K-Means (HOG, Histogramme, BoVW)
- DBSCAN (HOG, Histogramme, BoVW)

Conclusion

Ce projet nous a permis d'explorer la classification multi-classes d'images d'aliments à travers différents descripteurs et algorithmes de clustering. Nous avons mis en œuvre des descripteurs de forme (HOG), de texture (LBP), de luminosité (histogramme) et de vocabulaire visuel (BoVW), associés à trois algorithmes de clustering.

Les résultats montrent que, quel que soit le descripteur utilisé, les algorithmes de clustering non supervisés peinent à regrouper les images dans leurs classes réelles. Cela s'explique en partie par la complexité intrinsèque du problème, mais aussi par la qualité du dataset : les images contiennent souvent plusieurs aliments, des arrière-plans chargés, ou des aliments occupés très peu de place dans l'image.

La combinaison **K-Means + LBP** offre le meilleur compromis global, tandis que **BoVW** produit les meilleurs scores AMI, démontrant l'intérêt d'un descripteur plus riche.

Pistes d'amélioration

- **Nettoyage des données** : ne conserver que les images où l'aliment principal est clairement visible et unique.
- **Combinaison de descripteurs** : concaténer plusieurs descripteurs (par exemple LBP + HOG, ou Histogramme + BoVW) pour capturer à la fois texture, forme et structure, plutôt que de les tester isolément.
- **Augmentation de données** : enrichir le dataset pour améliorer la robustesse des descripteurs.
- **Histogramme couleur (HSV/RGB)** : Passer d'un histogramme de niveau de gris en histogramme de couleur.